

Respuesta al review de Gonzalo Ríos

Manuscrito: *Symbolic Regression as Spectral Feature Engineering: Discovering Interpretable Indices for Hydrothermal Alteration Mapping from Sentinel-2* **Target:** ISPRS Journal of Photogrammetry and Remote Sensing **Versión revisada:** 2026-04-22 (37 pp + supplementary)

Gonzalo, muchas gracias por el review. Los cinco puntos son los que un reviewer duro de ISPRS JPRS va a pedir en el primer round, y atenderlos antes del submit fortalece el paper sustancialmente. Los cambios que propusiste llevaron a dos hallazgos no triviales que valoricé en el propio manuscrito: (a) la crítica de autocorrelación espacial era correcta y el delta AUC bajo spatial block CV llega hasta -0.21 , pero las **relaciones de interés** ($SR \approx \text{raw}$, $SR > \text{classical}$, $SR + \text{classical best}$) **sobreviven a todos los esquemas**; y (b) las fórmulas SR descubiertas localmente en Cuprite son **estructuralmente distintas** a las chilenas, lo cual demuestra method transferability explícitamente en lugar de solo insinuarla.

Resumen ejecutivo

#	Punto	Estado	Nota
1	Fórmulas locales en Cuprite no reportadas	✓ Atendida	PySR re-corrido en Cuprite; tabla análoga a Table 3; fórmulas SWIR-dominated en vez de VNIR-dominated
2	Faltan baselines PCA(6) y MI-top-6	✓ Atendida	Ambos agregados a Table 7; PCA(6) supera a SR por $\sim 0.04 \rightarrow$ framing ajustado a “interpretabilidad sin costo vs raw bands”
3	Split 70/30 vulnerable a autocorrelación espacial	✓ Atendida (CRÍTICA)	$\Delta = -0.077$ a -0.21 según block size; las 3 relaciones centrales sobreviven
4	TOST sub-descrito	✓ Atendida	IC 95% fold-level, justificación $\epsilon=0.01$, bootstrap pareado polygon-level como check independiente
5	Silícico como brightness detector no retroalimenta workflow	✓ Atendida	Pareto analysis + propuesta metodológica “specificity gate over Pareto”

Páginas: 33 $\rightarrow$ 37 tras los cambios. **Experimentos nuevos corridos:** PySR on Cuprite, spatial block CV (5 block sizes $\times$ 4 feature sets), polygon-disjoint CV via DBSCAN, PCA(6) + MI(6) baselines, bootstrap paired polygon-level ($B=1000 \times 3$ feature sets). **Hallazgos no obvios:** (a) las fórmulas Cuprite redescubren ratios B11/B12 consistentes con alteration mineralogy local; (b) PCA(6) define el ceiling de dimensionality reduction y supera incluso a raw(10), forzando un reframing honesto de la contribución de SR.

Respuesta punto por punto

1. El claim de “method transferability” en Cuprite no está demostrado, solo insinuado

Recomendación: agregar una tabla análoga a la Tabla 3 para Cuprite, con las fórmulas descubiertas localmente. Si son estructuralmente distintas a las chilenas pero igual de efectivas, eso es el resultado de method transferability.

Qué se hizo: Re-corrí PySR con la configuración idéntica (Section~??) sobre los 10,500 pixels de training en Cuprite (hold-out 70/30, mismos hiperparámetros). Watchdog de RAM durante la corrida: peak 5.24 GB en 420 s.

Fórmulas descubiertas localmente en Cuprite vs Chile:

Clase	Chile	Cuprite	Cuprite AUC
Silicic	B04 – 0.135	log(B11/B12)	0.944
Adv. Argillic	0.83 – B02/B05	B11 – B12	0.938
Argillic-Phyllic	0.09/B05	tanh(B11) – B8A	0.898
Propylitic	B03 – 0.48·B11	((B12 – B08)/B07)²	0.664

Hallazgos: 1. **Las fórmulas son estructuralmente distintas.** Chile produce ratios VNIR (B02/B05, B04) y combinaciones VNIR–SWIR (B03 – 0.48·B11); Cuprite produce ratios SWIR puros (B11/B12, B11 – B12). Esto es geológicamente coherente: Cuprite es el benchmark clásico de alteración advanced-argillic donde los Al-OH (alunite, kaolinite) dominan el SWIR, mientras Atacama tiene diversidad espectral mayor incluyendo propilítica y Fe-oxides expresados parcialmente en VNIR. 2. **Las fórmulas locales superan a las importadas en 3 de 4 clases** (silicic: 0.94 local vs 0.74 importada de Chile; adv. argillic: 0.94 vs 0.70; argillic-phyllic: 0.90 vs 0.70+). 3. **La única excepción (propylitic) tiene causas estructurales identificables:** USGS merge de epidote/chlorite + carbonate (spectral heterogeneous class) y n=378 positivos vs 333 en Chile. Esto lo discutimos en el texto.

Ubicación: main.tex §5.5 subsección “Formulas discovered locally at Cuprite” + Tabla tab:cuprite_formulas (ahora L464–479 aprox). Script ejecutado: scripts/run_pysr_cuprite.py + watchdog scripts/watchdog_pysr Resultados en data/results/pysr_results_cuprite.json y data/results/equations_cuprite_*.csv.

2. Faltan los baselines canónicos de reducción de dimensionalidad

Recomendación: agregar PCA(6)+RF y MI-top-6+RF a la Tabla 6. Si SR no los supera, reformular a “SR da interpretabilidad sin costo frente a PCA”.

Qué se hizo: Corrí ambos baselines bajo los 3 esquemas de validación (pixel CV, polygon-disjoint, spatial block 5 km). Mutual information calculada fold-wise para evitar leakage; PCA ajustada solo en training fold.

Resultados clave (scripts/exp_dimred_baselines.py, data/results/dimred_baselines.json):

Feature set	Pixel CV	Polygon-disj	Block 5km
RF(10 raw)	0.899	0.822	0.707
RF(6 SR)	0.898	0.815	0.702
RF(7 classical)	0.878	0.789	0.683
RF(PCA 6)	0.934	0.863	0.747
RF(MI top-6)	0.841	0.763	0.680

Hallazgos: 1. **SR supera a MI-top-6 robustamente** (+0.02 a +0.06 en todos los esquemas) — MI selecciona bandas adyacentes correlacionadas y pierde las combinaciones no lineales que SR

expresa. 2. **PCA(6) es el mejor compressor** — supera a SR por 0.04–0.05 en todos los esquemas y excede incluso a raw(10). Define el ceiling de dimensionality reduction para 6 features. 3. **Acepté tu reformulación literal.** El paper ahora dice explícitamente: “*the contribution of SR is a closed-form, sensor-agnostic, and physically interpretable feature set with near-equivalent accuracy, not a new accuracy ceiling*” (abstract), y en el análisis: “*PCA trades interpretability for about 4–5 AUC points; whether that trade is worthwhile depends on whether the downstream consumer is a statistical model or a geologist*” (§5.4).

Ubicación: main.tex Tabla tab:spatial_robust (filas PCA + MI + Δ), §5.4 tercer párrafo de análisis, abstract (frase nueva sobre PCA vs MI), §7.7 Limitations punto 6 nuevo.

3. El split 70/30 es vulnerable a autocorrelación espacial

Recomendación (la más crítica): aclarar si el split fue polygon-disjoint. Si no, re-correr con spatial block CV o polygon-level split y reportar delta.

Qué se hizo: - **Diagnóstico:** Confirmado. El script run_pysr_atlas_gee.py usaba train_test_split(X, y, stratify=y) a nivel pixel (no polygon-disjoint). El npz no tiene polygon_id, pero el CSV sí tiene lon/lat por pixel. - **Polygon-disjoint CV:** Reconstruí 3,828 polígonos via DBSCAN espacial ($\epsilon \approx 110$ m, apropiado para Atlas Metalífero). Corré GroupKFold(5). - **Spatial block CV:** Bloques cuadrados de 1, 2, 5 y 10 km, GroupKFold(5). - **Compute total:** ~15 min across 5 schemes $\times$ 4 feature sets.

Resultados completos (data/results/spatial_block_cv.json + polygon_disjoint_cv.json):

Feature set	Pixel 5-fold	Polygon-disj (≈ 110 m)	Block 1 km	Block 5 km	Block 10 km
RF(raw)	0.899	0.822	0.842	0.707	0.686
RF(SR)	0.898	0.815	0.839	0.702	0.702
RF(classical)	0.878	0.789	0.822	0.683	0.674
RF(SR+classical)	0.920	0.839	0.862	0.719	0.708

Δ absolutos (autocorrelation inflation): raw mAUC cae de 0.899 $\rightarrow$ 0.822 (polygon-disjoint, $\Delta = -0.077$) $\rightarrow$ 0.707 (block 5km, $\Delta = -0.192$). **Por encima del umbral de 0.02 que planteaste** — la crítica era empíricamente correcta y grande.

Pero las 3 relaciones de interés sobreviven: - **Δ (SR – raw)** se mantiene en $[-0.007, +0.016]$ en todos los esquemas, **dentro del margen TOST $\epsilon = 0.01$.** - **Δ (SR – classical)** se mantiene en $[+0.017, +0.028]$, y es de hecho *ligeramente mayor* bajo polygon-disjoint CV que bajo pixel CV. - **SR+classical sigue siendo el best combination** en todos los esquemas.

Caveat: polygon-disjoint CV no puede evaluar la clase propylitic — sus 495 pixels forman un único cluster espacial compacto, dejándola ausente de todos los test folds. Esto se reconoce en el paper.

Cambios en el paper: - §3.7 Validation Strategy: nivel 1b nuevo “Intra-site (spatial robustness)” que documenta polygon-disjoint + spatial block CV. Citas nuevas Ploton et al. 2020 (Nature Comm.) y Meyer et al. 2019 (Ecol. Modelling). - **Tabla 7 tab:spatial_robust nueva:** 4 feature sets + 2 baselines $\times$ 5 esquemas, con filas Δ explícitas. - Abstract: frase nueva explícita sobre polygon-disjoint CV preservando la equivalencia. - §7.7 Limitations punto 1 reescrito completamente con la cuantificación empírica. - Framing general: pixel AUC tratado como upper bound; polygon-disjoint como defensible; Cuprite como primary out-of-site evidence.

Ubicación: main.tex §3.7 L246 (level 2 añadido), §5.4 Tabla 7 tab:spatial_robust, §7.7 punto 1 reescrito, abstract. Scripts: scripts/exp_spatial_block_cv.py, scripts/exp_polygon_disjoint_cv.py.

4. El TOST está sub-descrito para ser el resultado central

Recomendación: justificar $\varepsilon=1\%$, especificar unidad de remuestreo, reportar IC del Δ AUC. Opcional: bootstrap pareado a nivel polígono.

Qué se hizo todo:

Unidad de remuestreo especificada: fold-level mean AUC, $n=10$ folds estratificados. Explícito en el texto ahora.

IC 95% reportado: $\Delta = -0.00274$, $SE = 0.00109$, $t_{9,.025} = 2.262 \rightarrow 95\% \text{ CI} = [-0.0052, -0.0003]$. El CI no cruza cero (el test paired-t rechaza igualdad exacta), pero está completamente dentro del margen $\varepsilon=0.01$ (TOST rechaza no-equivalencia a $p<10^{-4}$).

Justificación operacional de $\varepsilon=0.01$: El paper ahora dice explícitamente que 0.01 es: - 1/10 de las diferencias class-level entre feature sets que sí tratamos como meaningful (SR-classical ≈ 0.02), - 1/20 de la spatial-autocorrelation inflation que documenta Table 7 (≈ 0.20 entre pixel y block 5 km), - el margen más estricto para el cual el test tiene power adecuado en $n=10$ folds ($\varepsilon=0.005$ sería underpowered dado $SE \approx 0.001$), - márgenes más laxos (0.02, 0.03, 0.05) rechazan a fortiori ($p<10^{-7}$).

Bootstrap pareado polygon-level (independiente, robusto a autocorrelación): - Entrené RF(raw) y RF(SR) con polygon-disjoint GroupKFold(5), OOF predictions. - Resample 3,828 polígonos con reemplazo, $B = 1000$. - **Mean bootstrap $\Delta = -0.0021$, 95% percentile CI = $[-0.0114, +0.0051]$, $P(|\Delta|<0.01) = 92.1\%$.** - El CI polygon-level es más ancho que el fold-level (esperado, removimos la autocorrelación-induced narrowing), pero centrado cerca de cero y mayoritariamente dentro del banda ± 0.01 .

Los dos procedimientos juntos (TOST fold-level + bootstrap polygon-level) hacen la equivalence claim más demandante que cualquiera por separado.

Ubicación: main.tex §5.4 Q2-Q3 primer párrafo reescrito completamente (era una oración, ahora son 3 párrafos densos). Script: scripts/exp_tost_expanded.py, resultados en data/results/tost_expanded.

5. El índice silícico falla en especificidad pero esto no retroalimenta el workflow

Recomendación: mostrar el Pareto front completo para silícica; discutir si alguna fórmula con contraste espectral existe dentro del budget. Si existe, convertir en hallazgo metodológico: “SR necesita prueba de especificidad como paso obligatorio”.

Qué se hizo:

Análisis del Pareto front silícica (data/results/equations_gee_Silicic.csv, 15 entradas):

Complexity	Loss	Bands	Contrast	Formula
1	0.1207	B03	no	B03
2	0.1188	B06	no	square(B06)
3	0.1161	B04	no (current)	B04 – 0.135
4	0.1152	B03,B12	YES	B03²/B12
7	0.1144	B03,B04,B12	YES	(B04/B12 – 0.34)·B03
8	0.1143	B03,B04,B12	YES	(B03/B12) ² ·B04·0.78

Hallazgos: 1. **Fórmulas con contraste espectral VNIR/SWIR Sí existen dentro del budget complexity ≤ 8 .** Tu intuición era la correcta: no es que el Pareto esté dominado por brillo a cualquier complejidad. 2. **AUC de los candidatos con contraste es comparable al brightness detector** (± 0.015 en pixel CV: 0.652–0.672 vs 0.667). 3. **¿Por qué PySR seleccionó brightness?** Porque el criterio por defecto get_best() de PySR usa score = loss improvement per complexity unit. En el

Pareto silícica, el drop más grande ocurre en complexity 3 (score 0.023), y los drops posteriores son menores (0.008, 0.001...). El selector por score está ciego a specificity.

Conversión en contribución metodológica (lo que pediste):

El paper ahora incluye en §6.4 Silicic una subsección “Pareto front and a methodological lesson” que:

- Muestra los candidatos alternativos con contraste espectral y sus AUCs bajo pixel CV + polygon-disjoint CV.
- Argumenta que en datasets donde una clase covaría fuertemente con un proxy escalar (aquí, albedo), el selector por defecto prefiere el proxy sobre el contraste mineralógico.
- Propone agregar un **specificity gate sobre el Pareto**: antes de retornar una fórmula, evaluarla sobre superficies distractoras de dominio (salt flats, sandy desert, snow, unaltered lithologies) y rechazar candidatos cuyo FPR sobre esas superficies exceda un threshold pre-definido.
- Posiciona esto como step generalizable del workflow SR-para-remote-sensing, no como disclaimer de una clase.

Ubicación: main.tex §6.4 Silicic Index, subsección “Pareto front and a methodological lesson” añadida al final de la subsección.

Cambios no solicitados pero derivados del review

- **Contribución #2 reescrita** explícitamente para posicionar SR como “unlike PCA-based dimensionality reduction... each SR feature is a closed-form expression with a direct mineral-spectroscopic interpretation and is deployable in any raster calculator without a fitted transformation”.
 - **Watchdog de RAM** para el PySR Cuprite (scripts/watchdog_pysr.py), por precaución operacional. Thresholds: warn 6 GB, kill 10 GB. La corrida alcanzó peak 5.24 GB (sin warning).
 - **Diálogo explícito con Mauricio en el abstract:** ahora el abstract reconoce tanto (i) la equivalencia bajo polygon-disjoint CV (tu punto 3) como (ii) el trade-off PCA vs interpretabilidad (tu punto 2).
 - **Citas nuevas:** Ploton et al. 2020 y Meyer et al. 2019 para spatial CV.
-

Puntos que me gustaría discutir contigo

1. **Propylitic en Cuprite (AUC 0.66 local).** La degradación es real — tiene dos causas probables: (a) USGS propylitic merge epidote/chlorite + carbonate (broader spectral class que la chilena), (b) n=378 positivos, clase minoritaria en Cuprite. ¿Lo dejamos como caveat en la Table o lo reforzamos como prueba de que el framework detecta correctamente clases compositionally heterogeneous?
 2. **PCA como ceiling.** El paper reconoce que PCA(6) supera a SR por 4–5 AUC points. ¿Te parece aceptable el framing de “SR no es el mejor compressor, es el mejor compressor interpretable”? O preferirías un tono más neutral tipo “SR y PCA ocupan puntos distintos del trade-off accuracy/interpretability”?
 3. **Specificity gate como workflow recommendation.** El paper lo deja propuesto pero no lo implementa numéricamente para todas las clases — solo para silícica, que es donde el problema se manifestó. ¿Vale la pena hacer un experimento completo con specificity gate implementado para las 6 clases antes del submit, o es suficiente como propuesta methodological?
 4. **Volumen: 37 pp.** ISPRS JPRS no tiene límite estricto pero algunos reviewers lo penalizan. Si los tres cambios arriba se implementan, puede crecer a 40+. ¿Movemos algo al supplementary (por ejemplo, la tabla completa de spatial block 1/2/5/10 km se puede resumir y el detalle al supplement)?
-

Archivos entregables

Archivo	Descripción
paper/main.pdf (37 pp, 7.1 MB)	Manuscrito revisado
paper/supplementary.pdf	Supplementary
paper/respuesta_gonzalo.md (este doc)	Respuesta formal punto por punto
scripts/run_pysr_cuprite.py	PySR on Cuprite (GR1)
scripts/watchdog_pysr.py	RAM watchdog (operacional)
scripts/exp_spatial_block_cv.py	Spatial block CV (GR3)
scripts/exp_polygon_disjoint_cv.py	Polygon-disjoint CV via DBSCAN (GR3)
scripts/exp_dimred_baselines.py	PCA + MI baselines (GR2)
scripts/exp_tost_expanded.py	TOST CI + polygon bootstrap (GR4)

Gracias nuevamente — el review mejoró materialmente la defensibilidad del paper. Quedo atento a tus comentarios sobre los 4 puntos abiertos.

Francisco